

# Modelo de Regresión Lineal para la Predicción de Calorías

## Abstract

Este documento explora la implementación de un modelo de regresión lineal múltiple para la predicción de calorías. Se menciona el dataset “Calories Burnt Prediction” y el proceso de limpieza, así como los criterios utilizados para seleccionar los datos pertinentes. También se explica el funcionamiento del modelo de regresión lineal, el cual presenta un error promedio aproximado de 25 calorías por predicción. Además, se describe el uso de un Random Forest a través de un framework, el cual obtuvo un error de predicción aproximado de 17 calorías por predicción.

## Introducción

El ser humano mantiene de manera constante un gasto energético basal, expresado en la quema de calorías, independientemente del tipo de actividad física realizada. Este gasto mínimo diario puede incrementarse según la intensidad, la duración y el tipo de ejercicio efectuado por la persona.

La estimación precisa del gasto calórico resulta compleja sin el uso de dispositivos especializados de medición. A pesar de los estudios, persisten creencias erróneas acerca de qué actividades favorecen en mayor medida la quema de calorías, como la comparación entre correr y realizar ejercicios de fuerza, o la influencia de factores como la edad.

En este trabajo se aborda la aplicación de técnicas de *Machine Learning* y de un modelo de regresión lineal múltiple para estimar el gasto calórico durante la actividad física. El enfoque considera parámetros corporales y el tiempo de ejercicio, con el propósito de aproximar de manera objetiva la cantidad de calorías consumidas.

## Datos

### Descripción del Conjunto de Datos

El *dataset* contiene 8 columnas: *User\_Id*, *Gender*, *Age*, *Height*, *Weight*, *Duration*, *Heart\_rate* y *Body\_temp*. A continuación se presenta una breve descripción del significado de cada columna:

- **User\_Id:** Identificador único para cada instancia, de tipo número entero.


- **Gender:** Texto con la palabra “female” para mujeres y “male” para hombres.
- **Age:** Número entero que representa la edad de la persona en años.
- **Height:** Número decimal que representa la estatura de la persona en centímetros.
- **Weight:** Número decimal que representa el peso de la persona en kilogramos.
- **Duration:** Minutos que duró el ejercicio.
- **Heart\_rate:** Número de pulsaciones por minuto del corazón de la persona (bpm).
- **Body\_temp:** Temperatura corporal de la persona en grados Celsius.

## Limpieza del Conjunto de Datos

El primer paso consistió en la limpieza de los datos, verificando que no hubiera valores faltantes. Posteriormente, se revisó la existencia de valores atípicos, dado que el modelo de regresión lineal es sensible a este tipo de observaciones, por lo que se prestó especial atención en esta etapa.


### Altura

La variable de altura presentó una distribución cercana a la normal, como se observa en el histograma. Para identificar valores atípicos se aplicó una prueba *z-test*, utilizando como criterio un valor de  $Z = 3$ . Toda instancia que se encontraba por encima de tres desviaciones estándar fue eliminada. De esta manera, se descartaron casos como el de una persona con una altura de 2.22 m, que, si bien corresponde a un valor real, no refleja la estatura promedio en la población adulta.




## Peso

En el caso del peso, la distribución no seguía un patrón normal. Por ello, se empleó el rango intercuartílico (IQR) como método para la detección de valores atípicos. Se eliminaron los registros con valores inferiores a  $Q1 - 1.5 \cdot IQR$  y superiores a  $Q3 + 1.5 \cdot IQR$ .



## Ritmo cardíaco

El ritmo cardíaco presentó una distribución aproximadamente normal, con valores mínimos de 67 bpm y máximos de 128 bpm. Estos rangos se consideran normales durante la actividad física, por lo que no fue necesario aplicar una prueba z-test ni eliminar instancias.



## Temperatura corporal

Respecto a la temperatura corporal, se consideró eliminar valores extremos de  $41.5^{\circ}\text{C}$ , ya que el rango tolerable para un adulto suele encontrarse entre  $39^{\circ}\text{C}$  y  $40^{\circ}\text{C}$  durante el ejercicio. Tomando en cuenta la media ( $40^{\circ}\text{C}$ ) y la desviación estándar ( $0.7^{\circ}\text{C}$ ), se decidió descartar los registros superiores a  $40.7^{\circ}\text{C}$ , definidos como el máximo aceptable en condiciones de esfuerzo físico.

## Género

La columna correspondiente al género se transformó a valores numéricos enteros. Se asignó el valor 0 a female y el valor 1 a male. Dado que la variable contenía únicamente dos categorías, no fue necesario aplicar one-hot encoding.

## Partición del Conjunto de Datos

El dataset fue dividido en tres subconjuntos: *train*, *validation* y *test*. El conjunto *train* se utilizó para entrenar el modelo y representó aproximadamente el 70% de los datos. El conjunto *validation* se empleó para prevenir el sobreajuste (*overfitting*), verificando que el error obtenido en *train* y *validation* fuera similar. Si el error en *train* resultaba muy bajo mientras que en *validation* era alto, esto indicaba que el modelo estaba memorizando los datos en lugar de aprender patrones.

Finalmente, el conjunto *test* se reservó únicamente para la fase final, con el propósito de evaluar el desempeño del modelo en predicciones y comprobar su comportamiento en un escenario real.

La partición de los datos se realizó con el apoyo de la librería *scikit-learn*.

# Modelo de regresión lineal múltiple


## Selección de Datos

Para seleccionar las variables necesarias para el modelo de regresión, se construyó una matriz de correlación que muestra los coeficientes de correlación de Pearson entre variables. El coeficiente de correlación mide el grado en que dos variables se relacionan entre sí, con valores que van de -1 a 1. Un valor cercano a 1 indica que cuando una variable aumenta, la otra también lo hace, mientras que un valor cercano a -1 indica que cuando una variable aumenta, la otra disminuye.


Entre las variables con mayor correlación con *Calories* (nuestra variable dependiente) se encuentran *Body\_Temp*, *Duration* y *Heart\_Rate*. Sin embargo, no se incluyeron *Duration* ni *Heart\_Rate*. La razón principal fue la colinealidad: por ejemplo, *Body\_Temp* y *Duration* están altamente correlacionadas entre sí, lo que genera problemas al momento de interpretar la importancia de las variables.

Cuando existe colinealidad, el modelo puede reconocer que al aumentar alguna de estas variables también aumentan las calorías, pero no logra distinguir con precisión cuál de ellas es la responsable. Como consecuencia, puede asignar un coeficiente positivo a una variable y valores muy pequeños o incluso negativos a las demás, lo que distorsiona la interpretación.

Finalmente, se decidió conservar *Body\_Temp* en lugar de *Duration*, a pesar de que esta última muestra una correlación más alta con *Calories* (0.96 vs. 0.82). La elección responde a un interés personal: analizar cómo la temperatura corporal influye en el gasto calórico, más allá de la duración del ejercicio, que constituye un factor más evidente y esperado.



Por otra parte, el análisis de dispersión confirma que *Duration*, *Body\_Temp* y *Heart\_Rate* presentan relaciones casi lineales con *Calories*, mientras que la relación con *Body\_Temp* tiende a mostrar un comportamiento más cercano a lo exponencial.



## Tratamiento de Datos

Escalar los datos es una práctica común en *Machine Learning*. En este modelo no fue la excepción. Los datos fueron normalizados utilizando la siguiente fórmula:

$$Z = \frac{x - \bar{x}}{\sigma}$$

donde  $x$  representa el valor original,  $\bar{x}$  la media de la variable y  $\sigma$  su desviación estándar.

El objetivo de esta transformación es expresar los datos en función de su distancia respecto a la media, medida en desviaciones estándar. De esta forma, se evita que variables con escalas grandes dominen el modelo. Además, este procedimiento beneficia al algoritmo de descenso de gradiente, ya que los valores dejan de tener magnitudes muy grandes y se encuentran en un rango estandarizado, lo que facilita las operaciones durante el entrenamiento.

## Función de hipótesis

La función de hipótesis es la que utilizamos para predecir y entrenar nuestro modelo. Se define de la siguiente manera:

$$h_{\theta}(x) = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n + b$$

El resultado de la función de hipótesis se expresa en las mismas unidades de la variable que deseamos predecir. En nuestro modelo, la función de hipótesis cuenta con 6 parámetros (5  $\theta$  y 1  $b$ ), lo que significa que consiste en la suma de cada parámetro multiplicado por su respectivo valor de entrada del *dataset*.

## Costo

La forma en que se calcula el error es tomando la diferencia entre el valor real y la predicción de nuestro modelo, elevándola al cuadrado y dividiéndola entre el número de instancias. Este procedimiento se conoce como **Error Cuadrático Medio** (*MSE, Mean Squared Error*), definido por la siguiente fórmula:

$$J(\theta, b) = \frac{1}{2m} \sum (h_{\theta}(x_i) - y_i)^2$$

De esta manera, podemos cuantificar el error en las predicciones en términos de “calorías al cuadrado”, es decir, qué tanto se desvía nuestro modelo del valor correcto.

Si se preguntan por qué la división es  $2m$  y no solo  $m$  (siendo  $m$  el número de instancias), la respuesta es que, al calcular la derivada, el exponente se cancela con el denominador. Como posteriormente se multiplica por la *learning rate*, no afecta dividir entre dos.

## Descenso de Gradiente

La fórmula utilizada para actualizar los parámetros es:

$$\Theta_j := \Theta_j - \frac{\alpha}{m} \sum_{i=1}^m [(h_{\Theta}(x_i) - y) x_i]$$

Durante cada época, los parámetros se actualizan hasta que se cumple alguna condición de parada, como alcanzar un número máximo de iteraciones o, en mi caso, cuando la diferencia entre el costo anterior y el costo actual es menor a 0.0001. Por debajo de este valor puede considerarse que el modelo ya no está aprendiendo de manera significativa.

El funcionamiento del descenso de gradiente es sencillo. Primero, se calcula el error de la predicción, que corresponde a la diferencia entre la función de hipótesis y el valor real. Este error se multiplica por la entrada de cada instancia y posteriormente se suman los resultados de



todas ellas, lo que constituye la pendiente del error. En un modelo de regresión lineal, el error siempre es una función cuadrática, por lo que el gradiente indica en qué dirección debemos moverlos para reducirlo.

Sin embargo, para evitar avanzar demasiado en esa dirección y caer en el mismo error en el lado opuesto, se introduce un valor de corrección llamado *learning rate*, representado por  $\alpha$ . Este valor disminuye la magnitud del ajuste. Finalmente, se resta el producto de la pendiente y el *learning rate* al valor actual del parámetro para actualizarlo. Este procedimiento se aplica a cada uno de los parámetros del modelo.

En nuestro caso fueron seis parámetros, todos inicializados en 1. Después de varias pruebas, se determinó que un valor de 0.001 para el *learning rate* fue el más adecuado, ya que permitió un entrenamiento más rápido y con menor error.


## Tree and Random Forest

Un árbol de decisión divide los datos en reglas del tipo “si-entonces”. Cada división se realiza en función de la variable que mejor separa las clases. El proceso continúa hasta que se cumplen condiciones de parada, como alcanzar una profundidad máxima o un número mínimo de muestras por nodo.

En nuestro caso, el framework del árbol de decisión permite interpretar de forma clara qué variables influyen más en las calorías quemadas.

El *Random Forest* es un conjunto de múltiples árboles, cada uno con un subconjunto de datos y variables. La predicción final se obtiene al promediar los resultados de todos los árboles, lo que genera un modelo más estable y robusto, reduciendo el *overfitting* que ocurre con un solo árbol.

En nuestro modelo, el bosque se conformó por 800 árboles, cada uno con una profundidad máxima de 5 niveles. Además, se estableció un mínimo de 10 muestras por división y 5 muestras por hoja, lo que evita particiones demasiado pequeñas y mejora la generalización. Estos parámetros permitieron lograr un equilibrio entre precisión y la complejidad del modelo.



StatisticsEasily.com

Source: [https://commons.wikimedia.org/wiki/File:Decision\\_Tree\\_vs\\_Random\\_Forest.png](https://commons.wikimedia.org/wiki/File:Decision_Tree_vs_Random_Forest.png)

## Resultados

### Primer modelo de regresión lineal

Cuando el primer modelo su aprendizaje Estos son los resultados

| Conjunto      | RMSE (cal) | MAE (cal) | R <sup>2</sup> |
|---------------|------------|-----------|----------------|
| Entrenamiento | 31.74      | 24.85     | 0.650          |
| Validación    | 31.67      | 24.87     | 0.648          |
| Prueba        | 32.91      | 25.74     | 0.635          |

| Parámetro | Valor |
|-----------|-------|
|-----------|-------|

|                        |        |
|------------------------|--------|
| $\theta_0$ (Age)       | 7.14   |
| $\theta_1$ (Body_Temp) | 42.43  |
| $\theta_2$ (Height)    | 0.0074 |
| Bias                   | 74.40  |

## Interpretación

### RMSE (Root Mean Squared Error)

Es la desviación promedio de las predicciones respecto al valor real. El modelo mostró un error de aproximadamente 31.7 calorías en entrenamiento, 31.7 en validación y 32.9 en prueba. Esto significa que, si una persona realmente quema 300 calorías, el modelo en promedio podría predecir valores que van desde ~268 hasta ~332 calorías.

### MAE (Mean Absolute Error)

Representa el error absoluto medio, es decir, cuántas calorías se equivoca el modelo en promedio sin importar la dirección del error. En nuestro caso, el MAE fue de alrededor de 25 calorías. Esto quiere decir que, si una persona quema 300 calorías, el modelo daría valores como 275 o 325 calorías. A diferencia del RMSE, el MAE no penaliza tanto los errores grandes, por lo que refleja un error más "típico". Como lo interpreté fu que el MAE es lo que se comunicaría a un cliente, mientras que el RMSE es lo que revisaría un experto, ya que muestra la sensibilidad del modelo ante errores grandes.

### R<sup>2</sup> (Coeficiente de Determinación)

Indica qué proporción de la variabilidad en las calorías quemadas es explicada por el modelo. En este caso, el modelo explica alrededor del 64% de la variación total en los datos, lo que implica que existe un 36% de variabilidad que no puede ser explicada por las variables elegidas. Dicho de otra forma, si tuviéramos 100 personas, el modelo lograría predecir correctamente a unas 64 de ellas, mientras que en las otras 36 la predicción se desviaría.

## Coeficientes del modelo

**Age (7.14):** Cada año adicional de edad se asocia con un incremento de aproximadamente 7 calorías.


**Body\_Temp (42.43):** Por cada grado extra de temperatura corporal, el modelo predice un aumento cercano a 42 calorías, lo que confirma su fuerte influencia en el gasto calórico.


**Height (0.0074):** La estatura tiene un peso casi nulo en comparación con las demás variables, por lo que su aporte resulta mínimo.

**Bias (74.40):** Representa el “gasto calórico base” a partir del cual se realizan las predicciones, es decir, el valor asignado cuando todas las variables independientes son cero.

## Train, Validation y Test

Veamos cómo fue el entrenamiento del modelo y cómo se reflejó en los conjuntos de *validation* y *test*.





Como podemos observar en estas gráficas, tanto el costo de *train* como el de *train y validation*, así como el de *validation y test*, presentan valores muy similares. Las líneas están muy próximas entre sí, lo que indica que el modelo está aprendiendo y no únicamente memorizando los valores. De lo contrario, las líneas de validación y prueba aparecerían más arriba que la de entrenamiento, lo que daría a entender que el modelo solo puede predecir con los valores que entrenó y no con datos nuevos.

Sin embargo, se observa un error de 500. ¿Qué significa este valor? En este caso corresponde al costo cuadrático, es decir, “calorías al cuadrado”, lo cual no es interpretable en la práctica. Por ello, utilizamos el RMSE para expresar el error en calorías y entenderlo mejor.

La gráfica es útil para analizar la varianza del modelo: cuando las líneas se encuentran juntas, significa que la varianza es baja. No obstante, esta representación no permite evaluar el sesgo. Para ello se recurre a métricas como el RMSE y el  $R^2$ . En nuestro caso, el modelo apenas explica el 64% de la varianza, lo que refleja un sesgo alto, aun cuando la varianza sea baja.

## Conclusión del primer modelo.

El modelo fue evaluado correctamente con los conjuntos de entrenamiento, validación y prueba, mostrando resultados similares entre ellos (RMSE  $\approx$  31–33, MAE  $\approx$  25,  $R^2 \approx$  0.64).

Dado que los resultados son consistentes, podemos concluir que no existe *overfitting*, sin embargo, el modelo podría ser demasiado simple para la forma en que se distribuyen los datos. Por ello, el valor de  $R^2$  cercano a 0.64 sugiere la presencia de *underfitting* más que de un buen ajuste.

Este modelo todavía puede mejorarse, y lo intentaremos al analizar nuestro modelo de *Random Forest* como un esfuerzo por superarlo..

## Arbol de Decisiones

Este modelo fue construido rápidamente con el objetivo de forzar un overfitting y mostrar un patrón de cómo se puede mejorar el desempeño del modelo.

El modelo de árbol de decisión se entrenó con los hiperparámetros por defecto, siendo el más relevante `max_depth=None`, lo que significa que el árbol puede crecer sin límite de profundidad hasta que cada hoja quede lo más pura posible. A esto se suman los valores predeterminados de `min_samples_split=2` y `min_samples_leaf=1`.

Bajo estas condiciones, el árbol mostró un rendimiento muy distinto entre entrenamiento, validación y prueba:

| Conjunto      | RMSE (cal) | MAE (cal) | R <sup>2</sup> |
|---------------|------------|-----------|----------------|
| Entrenamiento | 8.09       | 2.39      | 0.977          |
| Validación    | 35.55      | 24.63     | 0.557          |
| Prueba        | 34.46      | 23.60     | 0.600          |

Esto refleja un claro caso de *overfitting*, ya que el modelo prácticamente memorizó los datos de entrenamiento pero perdió capacidad de generalización frente a datos nuevos. Este experimento me ayudó a comprender que, si se permite que un solo árbol crezca sin control, terminará “memorizando” sus datos de entrenamiento y quedará perfecto únicamente para ese conjunto. Sin embargo, al enfocarse en casos tan específicos del *set* de entrenamiento, no logra aplicarlos correctamente a nuevos conjuntos de datos.

## Random Forrest

Teniendo en cuenta el árbol de decisión que acabamos de analizar, observamos que, en ausencia de múltiples árboles y con un crecimiento sin control, el modelo “memoriza” en lugar de generalizar. Justamente eso es lo que buscamos mejorar con el *Random Forest*.

Se realizó una prueba inicial con solo 5 árboles y los mismos hiperparámetros, obteniendo los siguientes resultados:

| Conjunto      | RMSE (cal) | MAE (cal) | R <sup>2</sup> |
|---------------|------------|-----------|----------------|
| Entrenamiento | 7.43       | 4.71      | 0.986          |
| Validación    | 15.92      | 11.53     | 0.935          |
| Prueba        | 15.80      | 11.34     | 0.937          |

## Importancia de Variables

- **Heart\_Rate:** 0.7441 → la variable más influyente en el gasto calórico.
- **Body\_Temp:** 0.1774 → segunda en importancia, con un peso considerable.
- **Age:** 0.0380 → contribuye de manera moderada.
- **User\_ID:** 0.0129 → aporta muy poco, probablemente sin relación real.
- **Weight:** 0.0116 → impacto bajo en el modelo.
- **Height:** 0.0095 → impacto casi nulo.
- **Gender:** 0.0064 → prácticamente irrelevante.

El framework cuenta con una función para identificar cuáles son las variables más importantes y, como podemos ver, *Heart\_Rate* es la más influyente. A diferencia del modelo de regresión lineal, el *Random Forest* no es tan sensible a la colinealidad. Aunque esto podría no representar un gran problema, sí afecta la forma en que se distribuye la importancia de las variables. Por

ello, considerando que próximamente trabajaremos con 800 árboles, lo más conveniente es no incluir tantas *features*; en consecuencia, se decidió conservar *Body\_Temp*, al igual que en la regresión lineal.

Al revisar nuevamente los resultados, se observa que el *overfitting* disminuye, aunque sigue siendo evidente al comparar los valores de  $R^2$  en *train*, *validation* y *test*. No obstante, ya comenzamos a identificar un patrón de mejora.

## Random Forrest Mejorado

Al observar que, al aumentar el número de árboles en el bosque, el *overfitting* comienza a disminuir, se decidió incrementar el modelo a 800 árboles y ajustar ligeramente los hiperparámetros. En particular, se evitó permitir la creación de un nuevo nodo con solo dos muestras y, además, se aumentó el mínimo de muestras necesarias para cada hoja. De esta manera, nos aseguramos de que el modelo no genere ramas demasiado específicas, sino que generalice mejor los casos.

Al final obtuvimos los siguientes resultados:

| Conjunto      | RMSE (cal) | MAE (cal) | $R^2$ |
|---------------|------------|-----------|-------|
| Entrenamiento | 16.57      | 12.10     | 0.929 |
| Validación    | 16.98      | 12.62     | 0.926 |
| Prueba        | 17.34      | 12.57     | 0.925 |

Como podemos observar, el problema de *overfitting* se resolvió y ahora los valores de  $R^2$  explican de manera similar el mismo porcentaje de la varianza con respecto a la media. Sin embargo, si prestamos atención, notaremos que el  $R^2$  es menor que cuando utilizamos únicamente 5 árboles.


Existen varias razones posibles para este caso. En primer lugar, podría tratarse simplemente de un efecto de azar, donde los valores de *test* y *validation* coincidieron de manera muy favorable con los de *train*. En segundo lugar, y más probablemente, los datos de este conjunto carecen de suficiente variabilidad, por lo que con una muestra pequeña ya se cubría una parte importante de los patrones. Al aumentar a 800 árboles, reducimos esa “suerte” inicial y logramos un promedio más estable que cubre la mayoría de los casos, lo que explica por qué los valores de  $R^2$  resultan muy similares entre los distintos conjuntos.





En conclusión, esta “mejora” presentó un MAE más alto y valores de  $R^2$  más bajos en comparación con el caso inicial, pero con la ventaja de no mostrar un *overfitting* tan marcado. Puede decirse que, aunque en este escenario el modelo predijo con menor precisión, lo hizo de manera más consistente, mientras que el primero dependía demasiado del azar para obtener buenos resultados.

Dado que el modelo mostró un error cercano a 12 calorías y explicó alrededor del 92% de la varianza, podemos afirmar que este modelo alcanza un buen *fitting*.

Veamos como predice nuestro último random forest






Como podemos ver, la mayoría de las veces el error de predicción con este modelo es muy cercano a cero. Con ello podemos afirmar que el sesgo del modelo es bajo, ya que la mayoría de las predicciones resultan bastante acertadas, sin desviarse demasiado hacia valores altos o bajos. Si la varianza fuera más alta, los errores alejados de cero serían más frecuentes.


## Regresión lineal mejora

Como mencionamos anteriormente, la regresión lineal se quedó corta, por lo que vamos a modificar los datos para evaluar si es posible mejorar el modelo.

Recordando la matriz de dispersión presentada en la sección de selección de datos.



Como se puede observar, las calorías y *Body\_Temp* muestran una relación que se asemeja a una función exponencial. Tomando esto en cuenta, existe una estrategia que puede ayudar al modelo de regresión lineal a predecir mejor: aplicar el logaritmo natural a la variable *Calories*. De esta forma, la correlación entre *Body\_Temp* y el logaritmo de las calorías será más alta.



Como podemos ver, *Body\_Temp* presenta una correlación más alta con *Calorias2* (el logaritmo natural de *Calories*) que con *Calories* (0.94 vs. 0.82).

Ahora que contamos con nuestra nueva variable, el siguiente paso es volver a entrenar el modelo con estas transformaciones. Sin embargo, es importante prestar mucha atención, al entrenar el modelo con el logaritmo natural de *Calories*, el resultado de las predicciones estará expresado en  $\ln(\text{Calories})$ . Por lo tanto, para calcular los errores y las métricas de evaluación es necesario elevar las predicciones a la base “e”, de modo que se obtengan nuevamente en unidades de calorías.


Al final tenemos estos resultados.

| Conjunto      | RMSE (cal) | MAE (cal) | R <sup>2</sup> |
|---------------|------------|-----------|----------------|
| Entrenamiento | 25.65      | 17.34     | 0.771          |
| Validación    | 25.78      | 17.53     | 0.767          |
| Prueba        | 26.11      | 17.65     | 0.770          |

Como podemos ver, hubo un incremento en el  $R^2$ . Nuestro modelo pasó de explicar aproximadamente el 64% a cerca del 77% de la varianza. Asimismo, el error medio se redujo de 25 a 17 calorías. Si bien estos resultados aún están lejos de los obtenidos con el *Random Forest*, representan una mejora considerable.



Veamos como fue el entrenamiento de este modelo






Como se puede observar ocurre los mismos resultados que en nuestro primer modelo de regresión lineal. Tenemos poca varianza, porque las líneas están juntas. Además ahora nuestras líneas están debajo del 500, lo que significa un mejor sesgo para el modelo.

Ahora vemos cómo se distribuyen sus errores.





Como podemos ver, en general el modelo presenta un error cercano a cero

Analizando la distribución de los errores, se observa que en general este modelo presenta errores más grandes y más dispersos. Mientras que el modelo de *Random Forest* tenía un rango aproximado de 60 calorías de error, este modelo alcanza un rango de poco más de 100 calorías.

## Análisis finales

| Modelo               | Conjunto      | RMSE (cal) | MAE (cal) | R <sup>2</sup> |
|----------------------|---------------|------------|-----------|----------------|
| Lineal (Calorías)    | Entrenamiento | 31.74      | 24.85     | 0.650          |
|                      | Validación    | 31.67      | 24.87     | 0.648          |
|                      | Prueba        | 32.91      | 25.74     | 0.635          |
| Lineal (ln-Calorías) | Entrenamiento | 25.65      | 17.34     | 0.771          |



|                        |               |       |       |       |
|------------------------|---------------|-------|-------|-------|
|                        | Validación    | 25.78 | 17.53 | 0.767 |
|                        | Prueba        | 26.11 | 17.65 | 0.770 |
| Árbol de Decisión      | Entrenamiento | 8.09  | 2.40  | 0.977 |
|                        | Validación    | 35.55 | 24.63 | 0.557 |
|                        | Prueba        | 34.46 | 23.60 | 0.600 |
| Random Forest          | Entrenamiento | 7.43  | 4.71  | 0.986 |
|                        | Validación    | 15.92 | 11.53 | 0.935 |
|                        | Prueba        | 15.80 | 11.34 | 0.937 |
| Random Forest Improved | Entrenamiento | 16.57 | 12.10 | 0.929 |
|                        | Validación    | 16.98 | 12.62 | 0.926 |
|                        | Prueba        | 17.34 | 12.57 | 0.925 |

### Modelo de Regresión Lineal (Calorías)

El modelo presentó *underfitting*. Mostró un sesgo (*bias*) alto, lo que significó que no pudo generalizar adecuadamente las variables, ya que se trata de un modelo lineal y las características no se comportan de forma suficientemente lineal. El sesgo alto se refleja en el  $R^2$ , con valores que rondan el 64%. El hecho de que los valores de  $R^2$ , MAE y RMSE se mantengan en rangos similares para los conjuntos de entrenamiento, validación y prueba indica que el modelo tiene poca varianza y se comporta de manera constante en predicciones con distintos conjuntos.

## Árbol de Decisión

Este modelo presentó *overfitting*. Se observa claramente cómo el  $R^2$  en entrenamiento alcanza un 97%, mientras que en validación y prueba no supera el 60%. Aunque en entrenamiento el sesgo es bajo, la varianza es muy alta, lo que lo convierte en un modelo poco confiable. Esto también se aprecia en que los valores de  $R^2$ , MAE y RMSE en entrenamiento son aproximadamente una séptima parte de los obtenidos en validación y prueba.

## Random Forest

En este modelo ocurre algo similar al árbol de decisión, con la diferencia de que la varianza no es tan alta. Sin embargo, al momento de evaluar con un conjunto de datos nuevos, no se puede esperar la misma efectividad que mostró durante el entrenamiento.

## Random Forest Mejorado

Este modelo alcanza un buen *fitting*. Presenta un sesgo bajo y no tiene problemas para generalizar patrones en los datos. Su  $R^2$  es aproximadamente de 92%. Al revisar su desempeño en entrenamiento, validación y prueba, se observa que los resultados son muy similares tanto en  $R^2$  como en MAE y RMSE, con diferencias que no superan las 2 calorías. En comparación con el modelo anterior, sacrificó algo de sesgo para reducir de forma notable la varianza. El sesgo sigue siendo bajo, lo que lo convierte en un modelo estable y preciso.

## Modelo de Regresión Lineal (ln-Calorías)

Este modelo también logra un *fitting* aceptable, aunque no tan bueno como el del *Random Forest mejorado*. Presenta un sesgo moderado con un  $R^2$  de 0.77 y poca varianza, ya que  $R^2$ , MAE y RMSE se mantienen en rangos similares para los tres conjuntos. No supera al modelo mejorado, pero puede considerarse una alternativa útil.

## Referencias

Lee, F. (2025, 29 julio). Bias Variance Tradeoff. *¿Qué es el equilibrio entre sesgo y varianza?* <https://www.ibm.com/think/topics/bias-variance-tradeoff>

GeeksforGeeks. (2025, 12 julio). *Bias and Variance in Machine Learning*. GeeksforGeeks. <https://www.geeksforgeeks.org/machine-learning/bias-vs-variance-in-machine-learning/>

`r2_score`. (s. f.). Scikit-learn. [https://scikit-learn.org/stable/modules/generated/sklearn.metrics.r2\\_score.html](https://scikit-learn.org/stable/modules/generated/sklearn.metrics.r2_score.html)

GeeksforGeeks. (2025b, julio 29). *Linear Regression in Machine learning*.  
GeeksforGeeks.

<https://www.geeksforgeeks.org/machine-learning/ml-linear-regression/>

GeeksforGeeks. (2025a, enero 27). *ML / Underfitting and Overfitting*. GeeksforGeeks.

<https://www.geeksforgeeks.org/machine-learning/underfitting-and-overfitting-in-machine-learning/>

Mwiti, D. (2023, 1 septiembre). *Random Forest Regression: When Does It Fail and Why?*  
neptune.ai.

<https://neptune.ai/blog/random-forest-regression-when-does-it-fail-and-why>